

# 恐怖感情の保持に着目した声質変換の主観評価と実用性の研究

山井航

## 1 はじめに

声質変換は、言語内容を保持しつつある声を別人の声質に変換する技術である [1]。この技術は様々なコミュニケーション、セキュリティ観点からの音声匿名化、音声データの拡張などの領域で活用される。実用例として、配信プラットフォームでは配信者の声を好きなキャラクター音声に変換して配信する動画コンテンツがあり、エンターテインメント性の向上や匿名性の確保を可能にしている。

深層学習を用いた声質変換モデルに関する評価によると、多くのモデルに対しては明瞭度や自然性に関しての評価が行われている一方で、感情や意図といったパラ言語情報の再現性に着目した評価は少ないことが指摘されている [2]。言語情報と同様にパラ言語情報もコミュニケーションにおいて重要な役割を担うため、これらの再現精度が低い場合、声質変換技術を用いたサービス全体の質が低下する可能性がある。このような背景から、声質変換モデルにおいて感情情報がどの程度保持されるかを評価することが重要であると考えられる。

本研究では声質変換を利用し、変換後音声の感情が保持されるかを主観評価した。実験は、怒り、悲しみ、驚き、恐怖、幸福、嫌悪といったエクマンが提唱した6つの基本感情 [3] のうち、恐怖を対象とした。本研究により、恐怖感情音声を声質変換することで、聴取者が変換後音声を恐怖として認識可能であるか、また認識可能である場合はどの程度劣化するのかを検証する。また、対象感情は恐怖に限定されるものの、得られた結果を基に感情保持に着目した声質変換の実用性を考察する。

## 2 本研究の位置づけ

### 2.1 関連研究

声質変換を利用したリアルタイム声質変換がコミュニケーションに与える影響を調べた研究がある [4]。影響度の評価として、声質変換を介したコミュニケーションと肉声を比較し、対話相手にとってコミュニケーションが難しくなるか、

声質変換利用者の対人魅力が変化するかを検証している。結果として、自然なコミュニケーションでは肉声と変換後音声の間に差を検出することは出来なかった。しかし、協力して作業を行う仕事のような難しいタスクでは声質変換の利用が好ましくないという結果が示された。原因として、感情や意図の不明瞭性、音声の加工感などが挙げられている。

感情ラベル付きデータセットの不足のため、声質変換を利用することによりデータセットの拡張を検討した研究も存在する [5]。拡張の有効性を検証するため、拡張前後の精度比較を感情識別モデルで評価している。実験結果として、声質変換を用いた拡張では、拡張前と比べて全体の感情認識精度が低下した。また、音の高低差が激しく変化する感情では不自然に感じる音声が多くなり感情を保持して変換することが難しいことが分かった。そのため、声質変換ベースのデータセット拡張を行う際には、感情を保持したまま自然な変換を行えるモデル設計や前処理が必要であると考えられている。

関連研究の感情識別モデルを用いた評価から、現状の声質変換では感情を保持した変換が難しいことが示唆されている。本研究では、この点を人間の知覚に基づいて検証するため、声質変換後の音声に対して聴取者が感情を認識できるかを主観評価によって検証する。

## 3 実験

### 3.1 利用する声質変換技術

声質変換には Retrieval-based Voice Conversion; RVC [6] を使用する。RVC は Variational Inference with adversarial learning for end-to-end Text-to-Speech; VITS [7] に基づく声質変換手法であり、高速で高品質な声質変換が可能とされている。RVC の特徴は少量のデータセットからでも、比較的良い声質変換モデルの作成、比較的貧弱な Graphics Processing Unit; GPU を利用した学習、WebUI が実装されているので、初学者でも簡単に利用可能であることが挙げられる。また、約 50 時間の高品質なオープンソース

データで訓練された pretrained モデルが利用可能である。

### 3.2 声質変換モデルの作成

RVC 上で声質変換モデルを作成するために、学習データとして ITA コーパスマルチモーダルデータベース [8] の「九州そら ノーマル 感情 100」, 「ずんだもん ノーマル 感情 100」をそれぞれ全て利用した。ITA コーパスマルチモーダルデータベースは東北イタコ, ずんだもん, 四国めたん, 九州そら, 中国うさぎの 5 話者がそれぞれ ITA コーパス [9] を読み上げた音声データや発話時の口唇動画から構成され, SSS 合同会社が研究目的のデータベースとして公開している。

声質変換モデル作成には九州そら, ずんだもんの各ノーマル感情 100 を, それぞれ 30 epoch で学習を行い 2 つの声質変換モデルを作成した。

### 3.3 実験用音声の作成

3.2 節で作成したモデルを用いて, Fig. 1 の流れで声質変換した。Fig. 1 は, 実験用音声作成の流れを示した図である。変換対象の音声は同データベースのうち「中国うさぎ ノーマル 感情 100」, 「中国うさぎ こわがり 感情 100」を利用した。データベース名のこわがりは恐怖感情のことである。実験用音声の作成のために, 中国うさぎのデータベースから各 40 個ずつ非復元抽出した。この計 80 個の変換前音声を 3.2 節で作成した 2 つの声質変換モデルにより変換した。これにより, 変換後の音声として各モデルのノーマル, こわがり音声生成され, 計 160 の音声を作成される。実験用音声は, 変換前の音声 80 個と変換後の音声 160 個を合わせた計 240 個の音声を利用する。

RVC で変換された音声のサンプリングは 48 kHz である。しかし, ITA コーパスマルチモーダルデータベースの音声のサンプリングは 96 kHz であるため, 変換前の音声に対してダウンサンプリングを行い全音声 48 kHz に統一した。また, 240 個の実験用音声はいずれも最大振幅を正規化して実験に利用した。

### 3.4 主観評価実験

3.3 節で作成した計 240 個の音声を用いて主観評価実験を行った。本実験では, 聴取者に音声の恐怖感情強度を評価してもらうため, 単極性の尺度を採用し, 評価は 0 (恐怖がない) から 6 (強い恐怖) までの 7 段階 [10] とした。回答の際




Fig. 1 実験用音声作成の流れ

は音声の文脈を考慮しないよう指示した。また, 実験前に聴取者ごとの音量調整を行い, 実験中は音量を変更しないよう指示した。聴取する音声の順序はランダムとし, 実験条件の詳細を Table 1 に示す

Table 1 実験条件

|           |                      |
|-----------|----------------------|
| 聴取者       | 男女 20 名              |
| 実験環境      | 騒音レベルが 20–30 dB の防音室 |
| オーディオ I/O | STAX SRM-D10 II      |
| ヘッドホン     | STAX SR-009          |
| サンプリング周波数 | 48 kHz/16 bit        |

## 4 主観評価結果

### 4.1 平均結果の算出

聴取者 20 名が同じ発話内容を聴取していることから, 実験で利用した 240 個の各音声に対して, 20 名の主観評価結果の平均を算出した。主観評価で得られた音声ごとの平均スコアの箱ひげ図を Fig. 2 に示す。Fig. 2 は縦軸に恐怖感情強度を示すスコアの値, 横軸に実験で利用した 6 種類の条件を示している。Fig. 2 より, ノーマル音声の恐怖感情強度は RVC の影響を受けないが, こわがり音声では恐怖感情強度が低下する傾向が確認された。また, ずんだもんは九州そらと比べて, 恐怖感情強度の低下が大きい結果となった。

### 4.2 検定

Table 2 フリードマン検定の多重比較検定結果

| 比較対象                        | p 値     |
|-----------------------------|---------|
| 中国うさぎ (こわがり) – 九州そら (こわがり)  | 0.023   |
| 中国うさぎ (こわがり) – ずんだもん (こわがり) | < 0.001 |
| 九州そら (こわがり) – ずんだもん (こわがり)  | < 0.001 |

実験によって得られたデータが正規分布に従うかを確認するために, 前段落で作成した音声ごとの平均結果に対してシャピロ・ウィルクの検定を実施した。検定結果から, 正規分布に従




Fig. 2 主観評価結果の箱ひげ図. \*\*\* は  $p < 0.001$  を, \* は  $p < 0.05$  を示す. 評価尺度は0~6の7段階 (0 = 怖がっていない, 3 = 怖がっている, 6 = 非常に怖がっている) である.

わなかったもので, 対応のある3群以上のノンパラメトリック検定であるフリードマン検定を行い, 多重比較検定を有意水準5%で実施した. 検定結果を Table 2 に示す. 検定結果から, 中国うさぎ (こわがり) と九州そら (こわがり), 中国うさぎ (こわがり) とずんだもん (こわがり) のそれぞれに有意差があると分かった. また, 九州そら (こわがり) とずんだもん (こわがり) にも有意差があるためモデル差も存在することが分かった.

## 5 考察

### 5.1 恐怖感情強度の低下

結果より, RVC による声質変換後のこわがり音声は, 変換前と比較して恐怖感情強度のスコアが低下する傾向が確認された. 一方で, こわがり条件のスコアはいずれも2以上であることから, 変換後音声においても恐怖の認識は可能であることが示唆される. 主観評価尺度においてスコア2は0 (怖がっていない), 3 (怖がっている) から, 3よりも1段階低い値であるため, 聴取者が恐怖を弱く認識していることを示す. この要因を検討するため, こわがり音声とノーマル音声に対して平均基本周波数 (F0 平均) を算出し, 各箱ひげ図を Fig. 3, Fig. 4 に示す.

Fig. 3, Fig. 4 は縦軸の F0 平均をメル尺度で表示し, 横軸は各キャラクターを示している. Fig. 3, Fig. 4 より, こわがり音声とノーマル音

声の F0 平均は, いずれもキャラクター間で大きな差が見られず, 声質変換後もピッチの高さ自体は維持されていた. また, こわがり音声の F0 平均はノーマル音声に比べて全体的に高い傾向を示した. この F0 平均の差は, 聴取者がピッチの高さを手がかりにすることで, ピッチの高い音声をこわがり音声として判断した可能性がある. そのため, 声質変換後においても F0 平均が維持されていることにより, 聴取者は恐怖感情の認識が可能であったと示唆される. この点は, Fig. 2 においてこわがり条件のスコアが2以上であることに繋がると考えられる. しかしながら, 恐怖として認識可能であっても, 変換後音声では恐怖感情強度が低下し, モデルの差異があることも分かった. この低下の要因として, RVC に伴う自然性の低下, 加工感, 不明瞭性が聴取者に違和感を与え, 注意を分散させることが恐怖感情強度を低下させたと考えられる. 実際に, 聴取者に主課題と副課題を並行的に行わせることで, 合成音声を聴取した際の認知負荷を評価した研究がある [11]. 実験結果として, 音声品質が低下するほど副課題の反応時間が遅くなり, より大きな認知負荷を要することが示された. 従って, 自然性の低下, 加工感, 不明瞭性が音声品質を低下させ, 聴取者の感情認識を妨げたと考えられる. 今後は, 恐怖感情強度のみを評価するのではなく, 各モデルに対して複数の評価軸で総合的に検証することが重要である.




Fig. 3 こわがり条件に対する F0 平均の箱ひげ図. 縦軸はメル尺度に変換してある.




Fig. 4 ノーマル条件に対する F0 平均の箱ひげ図. 縦軸はメル尺度に変換してある.

本実験では、主観評価音源を最大振幅で正規化を行い、実験前に聴取者ごとの音量調整を実施した。しかし、主観的な大きさが統一されていないため、聴取者ごとの大きさの違いが主観評価結果に影響を与えた可能性がある。今後は、音声品質の評価と共に主観的な大きさを統一する処理が必要となる。

## 5.2 感情保持に着目した RVC の実用性

実験結果から、変換後音声は恐怖感情強度が低下する傾向が見られるが、恐怖として認識可能であることが示された。評価対象は恐怖のみに限定されるが、感情保持に着目した RVC の特性が次のように示唆される。変換後も恐怖の認識が可能な点から、相手の感情を意識しないコミュニケーションでは実用上の影響が少ない可能性がある。一方で、仕事のような難しいタスクでは感情保持の弱まりで音声に違和感が生じ、聴取者の内容理解や意図推定を妨げる可能性がある。上記の仮説は関連研究 [5] であるように RVC を利用する場面によって、聴取者が好まない場面が存在するという知見の背景要因になると考えられ

る。従って、RVC を実用的に利用するには感情の低下を考慮し、適切な場面を選択する必要があると考えられる。上記の仮説を検証するために、恐怖に加えて他の感情に関しても同様の評価を行うことが重要である。

## 6 おわりに

本研究では RVC を用いた声質変換において、変換後音声に感情がどの程度保持されるかを検証するため、エクマンの基本 6 感情の恐怖を対象として主観評価実験を行った。その結果、F0 平均の維持により恐怖の認識は可能と示唆されるが、恐怖感情強度は低下する結果となった。また、ずんだもんは九州そらよりも恐怖感情強度の低下が大きくなった。

今後の課題として、本研究で確認された恐怖感情強度の低下要因を明らかにするには、恐怖の評価だけでなく、自然性、加工感、明瞭度といった他要因との関連も含めて検討を行う必要がある。また、音量に対しての主観的な大きさの統一処理が必要となる。RVC の実用性の検証に関しては恐怖以外の感情にも同様の評価を行い、様々な感情を考慮した RVC の評価が重要である。

## 参考文献

- [1] D. G. Childers, K. Wu, D. M. Hicks, and B. Yegnanarayana, "Voice conversion," Speech Communication, vol. 8, pp. 147–158, 1989.
- [2] T. Walczyna and Z. Piotrowski, "Overview of voice conversion methods based on deep learning," Applied sciences, vol. 13, no. 5, p. 3100, 2023.
- [3] P. Ekman, "Emotion in the human face," Malor Books, 2013.
- [4] 菅野聖真, 松井淑恵, "非対面会話でのコミュニケーション難易度と対人魅力にリアルタイム声質変換が与える影響," 日本音響学会誌, vol. 81, no. 1, pp. 80–83, 2024.
- [5] 生形優也, 杉山颯, 田村仁, "データセット拡張を用いた音声感情認識," IEICE Conferences Archives, 2024.
- [6] JTNEX, "Retrieval-based-Voice-Conversion-WebUI," <https://github.com/RVC-Project/Retrieval-based-Voice-Conversion-WebUI/blob/main/d>

ocs/jp/README.ja.md, (Accessed on 2026/01/18).

- [7] J. Kim, J. Kong, and J. Son, “Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech,” in Proc. ICML, pp. 5530–5540, 2021.
- [8] SSS 合同会社, “ITA コーパスマルチデータベース,” [https://zunko.jp/multimodal\\_dev/login.php](https://zunko.jp/multimodal_dev/login.php), (Accessed on 2026/01/18).
- [9] 小口純矢, 金井郁也, 小田恭央, 齊藤剛史, 森勢将雅, “ITA コーパス：パブリックドメインの音素バランス文からなる日本語テキストコーパスの構築と基礎評価,” 情報処理学会研究報告, vol. 2021-MUS-131, no. 31, pp. 1–6, 2021.
- [10] 坂上貴之, 川原純一郎, 木村英司, 三浦佳代, 行場次朗, 石金浩史, “基礎心理学実験法ハンドブック,” 朝倉書店, pp. 151–152, 2018.
- [11] A. Govender and S. King, “Measuring the cognitive load of synthetic speech using a dual task paradigm,” in Proc. INTER-SPEECH, pp. 2843–2847, 2018.